

# Optimisation numérique

Basé sur le poly de Quentin Mérigot

Luca Nenna\*

2022-2023

## Table des matières

<b>Table des matières</b>	<b>1</b>
<b>1 Existence, unicité, convexité</b>	<b>4</b>
1.1 Existence . . . . .	5
1.2 Notions de calcul différentiel . . . . .	6
1.3 Convexité et condition nécessaire et suffisante d'optimalité . . . . .	7
1.4 Stricte convexité et unicité du minimiseur . . . . .	10
<b>2 Descente de gradient à pas optimal</b>	<b>11</b>
2.1 Méthode de descente . . . . .	11
2.2 Descente de gradient à pas optimal . . . . .	12
<b>Bibliographie</b>	<b>16</b>

---

\*Université Paris-Saclay, CNRS, Laboratoire de mathématiques d'Orsay, 91405, Orsay, France.  
e-mail : [luca.nenna@universite-paris-saclay.fr](mailto:luca.nenna@universite-paris-saclay.fr)

# Introduction

**Motivation** Dans de nombreuses applications, la formulation naturelle du problème qu'on cherche à résoudre est un problème d'optimisation :

- Dans la méthode des moindres carrés, on remplace un système linéaire  $Ax = b$  surdéterminé et/ou n'ayant pas de solution (par exemple car certaines des égalités se contredisent) par le problème d'optimisation suivant :

$$\min_{x \in \mathbb{R}^N} \|Ax - b\|^2. \quad (1)$$

Le minimiseur  $x^*$  de ce problème vérifie “au mieux” la famille d'équation  $Ax = b$ . Au contraire, lorsqu'un système linéaire  $Ax = b$  admet plusieurs solutions, on peut en sélectionner une en considérant le problème

$$\min_{x \in K} \|x\|^2 \quad K = \{x \in \mathbb{R}^N \mid Ax = b\} \quad (2)$$

- Si  $\bar{x} \in \mathbb{R}^N$  représente un signal 1D échantillonné avec du bruit ( $\bar{x}_i$  représentant par exemple la mesure effectuée en un temps  $t_i$ ), on peut débruiter le signal en considérant le problème d'optimisation suivant, où  $\lambda > 0$  est un paramètre :

$$\min_{x \in \mathbb{R}^N} \|x - \bar{x}\|^2 + \lambda \sum_{1 \leq i \leq N-1} |x_{i+1} - x_i|^2 \quad (3)$$

un compromis entre deux comportements :  $x^*$  doit être proche de  $\bar{x}$  (c'est le rôle du premier terme  $\|x - \bar{x}\|^2$  de la fonction optimisée) mais doit également être “régulier”, au sens où deux valeurs successives  $x_i$  et  $x_{i+1}$  doivent être proches (second terme  $\sum_i |x_{i+1} - x_i|^2$ ).

- En finance, on peut considérer le problème de l'optimisation de portefeuille. Étant donnés  $N$  actifs, il s'agit de déterminer le pourcentage  $x_i \geq 0$  du portefeuille que l'on investit dans l'actif  $i$ . Comme on souhaite investir 100% du portefeuille, ce problème d'optimisation est accompagné d'une contrainte  $\sum_{1 \leq i \leq N} x_i = 1$ . On pourra donc considérer des problèmes d'optimisation *avec contraintes* de la forme

$$\min_{x \in \Delta} f(x) \text{ où } \Delta = \{x \in \mathbb{R}^N \mid \forall i, x_i \geq 0 \text{ et } \sum_i x_i = 1\}. \quad (4)$$

La fonction  $f$  est typiquement de la forme  $f(x) = \frac{1}{\varepsilon} |\langle c|x \rangle - r|^2 + \langle x|Qx \rangle$  :  $c \in \mathbb{R}^N$  représente le rendement des actifs et le premier terme cherche à fixer

le niveau de rendement  $\langle c|x \rangle = \sum_i c_i x_i$  à  $r$ . Le second terme de la fonction  $\langle x|Qx \rangle$  est une mesure de risque :  $Q$  est une matrice symétrique mesurant les corrélations entre actifs, et on cherche un investissement minimisant cette corrélation.

- En apprentissage automatique (*machine learning*), de nombreux problèmes peuvent être formulés comme des problèmes d'optimisation. Nous verrons par exemple des problèmes de classification, que l'on résoudra par régression logistique ou par machine à vecteurs support (*support vector machine*).

Pour plus d'exemple, on renvoie au livre de Boyd et Vanderberghe, qui est disponible gratuitement (en anglais) en ligne : <http://web.stanford.edu/~boyd/cvxbook/>.

**Problèmes avec/sans contrainte** On peut séparer les problèmes en deux grandes classes. Il y a d'une part les problèmes d'optimisation sans contraintes, où l'on cherche à minimiser une fonctionnelle sur  $\mathbb{R}^d$  ou sur son domaine de définition *ouvert* (les problèmes (1), (3) et la régression logistique sont de ce type). D'autre part, les problèmes d'optimisation avec contraintes, où l'on cherche à minimiser sur l'ensemble des points de  $\mathbb{R}^N$  vérifiant un certain nombre de contraintes d'égalité ou d'inégalité (les problèmes (2), (4) et les machines à vecteurs support sont de ce type).

**Convexité** Tout les algorithmes et exemples présentés dans ce cours relèvent de l'optimisation *convexe*, où aussi bien la fonction optimisée que le domaine d'optimisation sont supposés convexes. La raison fondamentale pour laquelle on se restreint à ce cas est que pour les problèmes d'optimisation convexe, un minimiseur local est *automatiquement* minimiseur global.

# Chapitre 1

## Existence, unicité, convexité

### Contents

1.1	Existence . . . . .	5
1.2	Notions de calcul différentiel . . . . .	6
1.3	Convexité et condition nécessaire et suffisante d'optimalité . . . .	7
1.4	Stricte convexité et unicité du minimiseur . . . . .	10

Dans cette première partie, on s'intéresse à un problème de minimisation d'une fonction  $f \in \mathcal{C}^1(\mathbb{R}^d)$  :

$$\inf_{x \in \mathbb{R}^d} f(x) \quad (\text{P})$$

**Définition 1.** On appelle :

- (i) *infimum* ou *valeur du problème* de (P) la valeur  $\inf_{\mathbb{R}^d} f$ .
- (ii) *minimiseur global* (ou simplement minimiseur) de (P) tout élément  $x^* \in \mathbb{R}^d$  vérifiant  $f(x^*) = \inf_{\mathbb{R}^d} f$ . On note  $\arg \min_{\mathbb{R}^d} f$  l'ensemble des minimiseurs de  $f$  (qui peut être vide), i.e.

$$\arg \min_{\mathbb{R}^d} f = \{x \in \mathbb{R}^d \mid f(x) = \inf_{\mathbb{R}^d} f\}.$$

- (iii) On appelle *suite minimisante* pour (P) toute suite  $x^{(0)}, \dots, x^{(k)}, \dots$  d'éléments de  $\mathbb{R}^d$  telle que  $\lim_{k \rightarrow +\infty} f(x^{(k)}) = \inf_{x \in \mathbb{R}^d} f(x)$ .

*Remarque 1.* Il est possible que le problème (P) n'admette pas de minimiseur : penser par exemple à  $f(x) = \exp(x)$  sur  $\mathbb{R}$ .

**Lemme 1.** *Il existe une suite minimisante pour le problème (P).*

*Démonstration.* Par définition de l'infimum, pour tout  $k > 0$ , il existe un élément  $x^{(k)} \in \mathbb{R}^d$  tel que  $\inf_{\mathbb{R}^d} f \leq f(x^{(k)}) \leq \inf_{\mathbb{R}^d} f + \frac{1}{k}$ , soit  $\lim_{k \rightarrow +\infty} f(x^{(k)}) = \inf_{\mathbb{R}^d} f$ .  $\square$

## 1.1 Existence

**Proposition 2.** Soit  $f \in \mathcal{C}^0(\mathbb{R}^d)$ . On suppose de plus qu'il existe  $x_0 \in \mathbb{R}^d$  tel que le sous-niveau  $S = \{x \in \mathbb{R}^d \mid f(x) \leq f(x_0)\}$  est compact. Alors le problème d'optimisation (P) admet un minimiseur global.

*Démonstration.* Si  $f(x_0) = \inf_{\mathbb{R}^d} f$  on a déjà l'existence d'un minimum, à savoir le point  $x_0$  lui-même. On suppose donc maintenant que  $f(x_0) > \inf_{\mathbb{R}^d} f$ . Soit  $(x^{(k)})_{k \geq 0}$  une suite minimisante, qui vérifie donc  $\lim_{k \rightarrow +\infty} f(x^{(k)}) = \inf_{\mathbb{R}^d} f < f(x_0)$ . Alors, pour  $k$  suffisamment grand, on a  $f(x^{(k)}) \leq f(x_0)$ , soit  $x^{(k)} \in S$ . Comme l'ensemble  $S$  est compact, on peut extraire une sous-suite  $(x^{(\sigma(k))})_{k \geq 0}$  qui converge vers un point  $x^\infty \in S$ . Alors, par continuité de  $f$  et par définition d'une suite minimisante on a  $f(x^\infty) = \lim_{k \rightarrow +\infty} f(x^{(\sigma(k))}) = \inf_{\mathbb{R}^d} f$ , et  $x^\infty$  minimise donc  $f$  sur  $\mathbb{R}^d$ .  $\square$

**Corollaire 3.** Soit  $f \in \mathcal{C}^0(\mathbb{R}^d)$  vérifiant

$$\lim_{\|x\| \rightarrow +\infty} f(x) = +\infty,$$

c'est-à-dire que

$$\forall L \in \mathbb{R}, \exists R \geq 0 \text{ t.q. } \|x\| \geq R \implies f(x) \geq L.$$

Alors (P) admet un minimiseur global.

*Démonstration.* Soit  $x_0 \in \mathbb{R}^d$  quelconque et  $S = \{x \in \mathbb{R}^d \mid f(x) \leq f(x_0)\}$ . Pour montrer l'existence d'un minimiseur, il suffit de démontrer que  $S$  est compact. L'ensemble  $S$  est fermé comme sous-niveau d'une fonction continue. Supposons  $S$  non borné : pour tout  $k$ , il existe alors  $x^{(k)} \in S$  tel que  $\|x^{(k)}\| \geq qk$ . Ainsi,  $\lim_{k \rightarrow +\infty} x^{(k)} = +\infty$  et  $f(x^{(k)}) \leq f(x_0)$ , contredisant l'hypothèse.  $\square$

**Corollaire 4.** Soit  $f \in \mathcal{C}^0(\mathbb{R}^d)$  et vérifiant la propriété suivante :

$$\forall x \in \mathbb{R}^d, f(x) \geq C \|x\|^p + D,$$

où  $C > 0, D \in \mathbb{R}$  et  $p > 0$ . Alors le problème (P) admet un minimiseur.

*Démonstration.* Soit  $x_0 \in \mathbb{R}^d$  quelconque et  $S = \{x \in \mathbb{R}^d \mid f(x) \leq f(x_0)\}$ . Pour pouvoir appliquer le théorème précédent, il suffit de démontrer que  $S$  est compact. Comme on sait déjà que  $S$  est fermé comme sous-niveau d'une fonction continue, il suffit de démontrer que cet ensemble est borné. Or, pour tout  $x \in S$ , on a

$$C \|x\|^p + D \leq f(x) \leq f(x^{(0)})$$

soit  $\|x\|^p \leq E := |f(x^{(0)}) - D|/C$ . Ainsi, l'ensemble  $S$  est contenu dans la boule centrée en 0 et de rayon  $\sqrt[p]{E}$  et est donc borné.  $\square$

## 1.2 Notions de calcul différentiel

**Définition 2** (Différentiabilité). Soit  $f : \Omega \subset V \rightarrow W$  avec  $\Omega$  ouvert. On dit que  $f$  est différentiable en  $x_0 \in \Omega$  si et seulement si il existe une application linéaire continue  $L \in \mathcal{L}(V, W)$  telle que

$$f(x_0 + h) \underset{h \rightarrow 0}{=} f(x_0) + L(h) + o(\|h\|).$$

L'application linéaire  $L$  est notée  $d_{x_0}f \in \mathcal{L}(V, W)$  et elle est dite différentielle de  $f$  en  $x_0$

L'application  $f$  est alors  $\mathcal{C}^1(\Omega)$  si elle est différentiable dans tout point  $x$  dans  $\Omega$  et l'application

$$\begin{aligned} df : \Omega &\rightarrow ((V, W), \|\cdot\|_{\text{op}}) \\ x_0 &\mapsto d_{x_0}f \end{aligned}$$

est continue.

**Définition 3** (Dérivée directionnelle). Soit  $f : \Omega \subset V \rightarrow W$  avec  $\Omega$  ouvert,  $x_0 \in \Omega$  et  $h \in V$ . Quand elle existe, la limite

$$\lim_{t \rightarrow 0} \frac{f(x_0 + th) - f(x_0)}{t}$$

est appelée dérivée directionnelle de  $f$  dans la direction

*Remarque 2.* Si  $f$  est différentiable en  $x_0$  alors elle admet une dérivée directionnelle dans toute direction  $h \in V$  et

$$d_{x_0}f(h) = \lim_{t \rightarrow 0} \frac{f(x_0 + th) - f(x_0)}{t}.$$

La réciproque n'est pas vraie en général! Par exemple

$$f(x, y) = \begin{cases} \frac{y^2}{x} & \text{if } x \neq 0 \\ y & \text{if } x = 0. \end{cases}$$

**Définition 4.** Soit  $f \in \mathcal{C}^1(\mathbb{R}^d)$ . Par le théorème de Riesz il existe un unique vecteur de  $V$ , noté  $\nabla f(x_0)$  et appelé *gradient* de  $f$  en  $x_0$ , tel que

$$d_{x_0}f(h) = \langle \nabla f(x_0), h \rangle \quad \forall h \in V.$$

Soit  $\langle \cdot, \cdot \rangle$  le produit scalaire usuel et  $(e_i)_{1 \leq i \leq d}$  la base canonique de  $\mathbb{R}^d$ , on a

$$\nabla f(x) = \left( \frac{\partial f}{\partial e_i}(x) \right)_{1 \leq i \leq d} \quad \text{où} \quad \frac{\partial f}{\partial e_i}(x) = \lim_{\varepsilon \rightarrow 0} \frac{1}{\varepsilon} (f(x + \varepsilon e_i) - f(x)).$$

Dans la suite on prendra toujours  $V = \mathbb{R}^d$  et  $W = \mathbb{R}$ .

*Exemple 1.* Considérons  $f(x) = \|x\|^2$  sur  $\mathbb{R}^d$ . En développant le carré de la norme, on obtient  $f(x + v) = \|x\|^2 + \langle 2x | v \rangle + \|v\|^2$ . On en déduit que  $\nabla f(x) = 2x$ , ce qui est conforme avec le calcul.

On dit que  $f : \Omega \subset V \rightarrow W$  est deux fois différentiable en  $x_0$  si elle est différentiable dans un voisinage de  $x_0$  et  $df$  est différentiable en  $x_0$ . On note cette dérivée  $d_{x_0}^2$  qui est un élément de  $\mathcal{L}(V, \mathcal{L}(V, W))$ . En particulier on a que  $d_{x_0}^2 f(h, k)$  est la dérivée directionnelle de  $x \mapsto d_x f(h)$  dans la direction  $k$ .

**Définition 5.** Soit  $f \in \mathcal{C}^2(\Omega)$ , où  $\Omega \subseteq \mathbb{R}^d$  est un ouvert. On appelle *hessienne* de  $f$  en  $x_0 \in \Omega$  la matrice associée à la forme bilinéaire  $d_{x_0}^2$  dans la base canonique. En particulier

$$D^2 f(x) = \left( \frac{\partial^2 f}{\partial e_i \partial e_j}(x) \right)_{1 \leq i, j \leq d},$$

où l'on a noté  $(e_i)_{1 \leq i \leq d}$  la base canonique de  $\mathbb{R}^d$ . et où

## 1.3 Convexité et condition nécessaire et suffisante d'optimalité

### 1.3.1 Convexité

**Définition 6.** Une fonction  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  est *convexe* si

$$\forall (x, y) \in \mathbb{R}^d, \forall t \in [0, 1], f((1-t)x + ty) \leq (1-t)f(x) + tf(y).$$

**Exercice 1.** Soit  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  une fonction convexe. Montrer que l'ensemble

$$\{x \in \mathbb{R}^d \mid f(x) \leq C\}$$

est convexe quel que soit  $C$ . En déduire que l'ensemble des minimiseurs de (P) est un ensemble convexe fermé (possiblement vide).

**Proposition 5.** Soit  $f \in \mathcal{C}^1(\mathbb{R}^d)$ . Alors les propositions suivantes sont équivalentes :

- (i)  $f$  est convexe sur  $\mathbb{R}^d$ ,
- (ii)  $\forall x, y \in \mathbb{R}^d$ , la fonction  $g : t \in [0, 1] \mapsto f((1-t)x + ty)$  est convexe.
- (iii)  $\forall x, y \in \mathbb{R}^d$ ,  $f(y) \geq f(x) + \langle y - x | \nabla f(x) \rangle$ ,
- (iv)  $\forall x, y \in \mathbb{R}^d$ ,  $\langle \nabla f(x) - \nabla f(y) | x - y \rangle \geq 0$ .

**Lemme 6.** Soit  $f \in \mathcal{C}^1(\mathbb{R}^d)$ . Étant donnés  $x \in \Omega$  et  $v \in \mathbb{R}^d$ , on définit  $x_t = x + tv$  et  $g(t) = f(x_t)$ . Alors,

$$g'(t) = \langle \nabla f(x_t) | v \rangle. \quad (1.1)$$

*Démonstration de la proposition 5.* (i)  $\iff$  (ii) conséquence directe de la définition.

(ii)  $\implies$  (iii). Soit  $x, y$  dans  $\mathbb{R}^d$  et  $g : t \mapsto f(x_t)$  où  $x_t = (1-t)x + tv = x + t(y-x)$ , qui est convexe par hypothèse. Par convexité, on a  $g(t) \geq g(0) + tg'(0)$ , soit par le lemme  $f(x) + \langle \nabla f(x) | y - x \rangle \leq f(y)$ .

(iii)  $\implies$  (iv) Il suffit de sommer l'inégalité (iii) et la même inégalité où l'on a inversé le rôle de  $x$  et  $y$ .

(iv)  $\implies$  (ii) Soit encore  $g : t \mapsto f(x_t)$  où  $x_t = (1-t)x + tv = x + t(y-x)$ . Comme  $g'(t) = \langle \nabla f(x_t) | y - x \rangle$ , (lemme 6) l'inégalité (iv) appliquée en  $x_s$  et  $x_t$  (où  $t > s$ ) nous donne

$$g'(t) - g'(s) = \langle \nabla f(x_t) - \nabla f(x_s) | y - x \rangle = \frac{1}{t-s} \langle \nabla f(x_t) - \nabla f(x_s) | x_t - x_s \rangle \geq 0,$$

et  $g'$  est donc croissante sur  $[0, 1]$ . Ainsi,  $g$  est convexe.  $\square$

**Lemme 7** (Taylor-Lagrange). Soit  $f \in \mathcal{C}^2(\mathbb{R}^d)$ ,  $x, v \in \mathbb{R}^d$  et  $x_t = x + tv$ . Alors,

$$\forall t \geq 0, \exists s \in [0, t], \quad f(x_t) = f(x) + t \langle \nabla f(x) | v \rangle + \frac{t^2}{2} \langle D^2 f(x_s) v | v \rangle.$$

**Lemme 8.** Soit  $\Omega \subseteq \mathbb{R}^d$  ouvert,  $f \in \mathcal{C}^2(\Omega)$ ,  $x \in \Omega$  et  $v \in \mathbb{R}^d$  et  $g : t \mapsto f(x_t)$  où  $x_t = x + tv$ . Alors,

$$g''(t) = \langle D^2 f(x_t) v | v \rangle. \quad (1.2)$$

*Démonstration.* On fait le calcul en coordonnées, en notant  $(e_k)_k$  la base canonique :

$$g(t) = f\left(x + \sum_k t v_k e_k\right)$$

$$g'(t) = \sum_i v_i \frac{\partial f}{\partial e_i} \left( x + \sum_k t v_k e_k \right) = \langle \nabla f(x_t) | v \rangle$$



$$g''(t) = \sum_i \sum_j v_i v_j \frac{\partial^2 f}{\partial e_j \partial e_i} \left( x + \sum_k t v_k e_k \right) = \langle D^2 f(x_t) v | v \rangle \quad \square$$

**Proposition 9.** Soit  $f \in \mathcal{C}^2(\mathbb{R}^d)$ . Si  $\forall x \in \mathbb{R}^d, D^2 f(x) \succeq 0$ , alors  $f$  est convexe.

*Démonstration de la proposition 9.* Considérons  $x, y \in \Omega$  et  $g(t) = f(x_t)$  où  $x_t = (1-t)x + ty$ . Alors,  $g''(t) = \langle D^2 f(x_t)(y-x) | y-x \rangle$  est positif par hypothèse, de sorte que par Taylor-Lagrange

$$g(1) = g(0) + g'(0) + \frac{s^2}{2} g''(s) \geq g(0) + g'(0),$$

soit  $f(y) \geq f(x) + \langle \nabla f(x) | y-x \rangle$ . La proposition 5 montre que  $f$  est convexe.  $\square$

### 1.3.2 Condition nécessaire d'optimalité

**Théorème 10 (Fermat).** Soit  $f \in \mathcal{C}^1(\mathbb{R}^d)$ , et  $x^*$  un minimiseur de (P). Alors

$$\nabla f(x^*) = 0. \quad (\text{équation d'Euler})$$

*Remarque 3.* La contraposée est fautive : prendre  $f(x) = x^3$  sur  $\Omega = \mathbb{R}$  : le point 0 vérifie  $f'(0) = 0$  mais n'est pas un minimiseur (même local).

*Démonstration.* Si  $x^*$  est un minimiseur de  $f$  sur  $\Omega$ , on a pour tout  $\varepsilon \in \mathbb{R}$ ,  $f(x^* + \varepsilon e_i) \geq f(x^*)$ . Ainsi,

$$\forall 0 < \varepsilon \leq \varepsilon_0, \quad \frac{f(x^* + \varepsilon e_i) - f(x^*)}{\varepsilon} \geq 0.$$

En passant à la limite, on obtient  $\frac{\partial f}{\partial e_i}(x^*) \geq 0$ . De même, en considérant le cas  $\varepsilon < 0$

$$\forall -\varepsilon_0 \leq \varepsilon < 0, \quad \frac{f(x^* + \varepsilon e_i) - f(x^*)}{\varepsilon} \leq 0,$$

d'où l'on tire en passant à la limite  $\frac{\partial f}{\partial e_i}(x^*) \leq 0$ , soit *in fine*  $\frac{\partial f}{\partial e_i}(x^*) = 0$ .  $\square$

### 1.3.3 Condition suffisante d'optimalité

**Théorème 11.** Soit  $\Omega \subseteq \mathbb{R}^d$  un ouvert convexe et  $f \in \mathcal{C}^1(\Omega)$  convexe. Alors  $x^* \in \Omega$  est un minimiseur de (P) si et seulement si  $\nabla f(x^*) = 0$ .

*Démonstration.* Le théorème de Fermat nous donne déjà le sens direct. Pour la réciproque, il suffit de remarquer que si  $\nabla f(x^*) = 0$ , la proposition précédente donne

$$\forall y \in \Omega, f(y) \geq f(x^*) + \langle y - x^* | \nabla f(x^*) \rangle = f(x^*),$$

de sorte que  $x^*$  est bien un minimiseur de (P).  $\square$

## 1.4 Stricte convexité et unicité du minimiseur

**Définition 7.** Une fonction  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  est strictement convexe si

$$\forall x \neq y \in \mathbb{R}^d, \forall t \in ]0, 1[, f((1-t)x + ty) < (1-t)f(x) + tf(y).$$

**Proposition 12.** Soit  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  strictement convexe. Alors  $f$  admet au plus un minimiseur sur  $\mathbb{R}^d$ .

*Démonstration.* Par l'absurde, supposons que  $f$  admette deux minimiseurs distincts  $x^* \neq y^* \in \mathbb{R}^d$ . Alors, par stricte convexité de la fonction  $f$  on a  $f(z^*) < \frac{1}{2}(f(x^*) + f(y^*)) = f(x^*)$ , où  $z^* = \frac{1}{2}(x^* + y^*)$ , contredisant l'hypothèse que  $x^*$  minimise  $f$ .  $\square$

*Remarque 4.* Cette proposition ne dit rien de l'existence d'un minimiseur.

## Chapitre 2

# Descente de gradient à pas optimal

On souhaite résoudre numériquement le problème de minimisation d'une fonction  $f \in \mathcal{C}^0(\mathbb{R}^d)$ . Comme en général il n'est pas raisonnable d'espérer calculer de manière exacte un minimiseur ou même la valeur de l'infimum du problème (P), on cherchera à l'*approcher*. Il s'agira de construire une suite  $(x^{(k)})_{k \geq 0}$  de points vérifiant une des deux propriétés suivantes :

- (a) la suite  $x^{(k)}$  est minimisante pour (P), i.e.  $\lim_{k \rightarrow +\infty} f(x^{(k)}) = \inf_{\mathbb{R}^d} f$ .
- (b) la suite  $x^{(k)}$  converge vers un minimiseur de  $f$  sur  $\mathbb{R}^d$ .

Dans ce chapitre, nous nous intéresserons à la construction de suites  $x^{(k)}$  vérifiant la seconde propriété (qui est bien sûr plus forte que la première).

### 2.1 Méthode de descente

**Vocabulaire** On appelle *méthode de descente* un procédé algorithmique permettant de construire itérativement une suite vérifiant (a) ou (b). Typiquement, une méthode de descente prend la forme suivante

$$\begin{cases} d^{(k)} = \dots & \text{direction de descente} \\ t^{(k)} = \dots & \text{pas de descente} \\ x^{(k+1)} = x^{(k)} + t^{(k)} d^{(k)} \end{cases}$$

Un tel algorithme est appelé méthode de descente si  $f(x^{(k+1)}) \leq f(x^{(k)})$ . Dans ce cours, on considèrera les possibilités suivantes :

- (a) La *direction de descente* peut être égale à l'opposé du gradient,  $d^{(k)} = -\nabla f(x^{(k)})$ , auquel cas on parle de méthode de descente de gradient. Lorsque  $f$  est  $\mathcal{C}^2$ , il peut être plus avantageux de choisir  $d^{(k)} = -D^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$ , auquel cas on parle de méthode de Newton.
- (b) Le *pas de descente* peut être choisi constant ( $t^{(k)} = \tau$ ), optimal (cf (2.1)), ou obtenu par des constructions un peu plus complexes, permettant de garantir la convergence de la méthode.

**Définition 8.** Soit  $f \in \mathcal{C}^0(\mathbb{R}^d)$ . On appelle *direction de descente* en  $x \in \mathbb{R}^d$  tout vecteur  $v$  tel que  $\exists \tau > 0, \forall t \in [0, \tau], f(x + tv) < f(x)$ .

**Exercice 2.** Si  $f \in \mathcal{C}^1(\mathbb{R}^d)$  et  $\langle v | \nabla f(x) \rangle < 0$ , alors  $v$  est une direction de descente.

Si  $f$  est différentiable en  $x$ , on a  $f(x + tv) = f(x) + t\langle \nabla f(x) | v \rangle + o(t)$ . On cherche naturellement une direction de descente rendant le produit scalaire  $\langle \nabla f(x) | v \rangle$  le plus petit possible, menant au choix de  $d^{(k)} = -\nabla f(x^{(k)})$  :

**Lemme 13.** Soit  $f \in \mathcal{C}^1(\mathbb{R}^d)$  et  $x_0 \in \mathbb{R}^d$ . Alors,  $\min_{\|v\|=1} d_{x_0} f(v) = -\|\nabla f(x_0)\|$  et si  $\nabla f(x_0) \neq 0$ , l'unique minimiseur est  $v = -\nabla f(x_0) / \|\nabla f(x_0)\|$ .

*Démonstration.* On a  $d_{x_0} f(v) = \langle \nabla f(x_0) | v \rangle \geq -\|\nabla f(x_0)\| \|v\|$  par Cauchy-Schwarz, avec égalité si et seulement si  $v$  est positivement homogène à  $-\nabla f(x_0)$ . Comme  $\|v\| = 1$ , on a  $v = -\nabla f(x_0) / \|\nabla f(x_0)\|$ .  $\square$

## 2.2 Descente de gradient à pas optimal

**Définition 9.** Soit  $f \in \mathcal{C}^1(\mathbb{R}^d)$ . L'algorithme de descente de gradient à pas optimal est donné par :

$$\begin{cases} d^{(k)} = -\nabla f(x^{(k)}) \\ t^{(k)} \in \arg \min_t f(x^{(k)} + td^{(k)}) \\ x^{(k+1)} = x^{(k)} + t^{(k)} d^{(k)} \end{cases} \quad (2.1)$$

*Remarque 5.* Par construction, les itérées vérifient

$$\begin{aligned} f(x^{(k+1)}) &\leq f(x^{(k)}) \\ \langle \nabla f(x^{(k+1)}) | \nabla f(x^{(k)}) \rangle &= 0. \end{aligned}$$

Pour la deuxième égalité, il suffit de remarquer que si l'on pose  $g(t) = f(x^{(k)} + td^{(k)})$ , alors par définition de  $t^{(k)}$ ,

$$g'(t^{(k)}) = 0 = \langle \nabla f(x^{(k)} + t^{(k)} d^{(k)}) | d^{(k)} \rangle = \langle \nabla f(x^{(k+1)}) | \nabla f(x^{(k)}) \rangle.$$

*Remarque 6.* Pour pouvoir mettre en œuvre cet algorithme il faut pouvoir calculer le pas optimal  $t^{(k)}$  à chaque itération, ce qui implique de résoudre un problème d'optimisation (sur  $\mathbb{R}$ ). Ceci n'est faisable de manière exacte que dans un nombre très limité de cas. En général, on préférera d'autre méthode de calcul du pas.

*Exemple 2.* Soit  $f : x \in \mathbb{R}^d \mapsto \frac{1}{2}\langle Qx|x \rangle + \langle b|x \rangle$  où  $Q$  est une matrice symétrique définie positive. Alors  $f$  est strictement convexe et  $\nabla f(x) = Qx + b$ . Soit  $x^{(k)} \in \mathbb{R}^d$ ,  $d^{(k)} = -\nabla f(x^{(k)})$ . Pour calculer le pas  $t^{(k)} \in \mathbb{R}$ , on cherche le minimum de  $g : t \in \mathbb{R} \mapsto f(x_t)$  où  $x_t = x^{(k)} + td^{(k)}$ . La fonction  $g$  est convexe et atteint donc son minimum en l'unique point  $t^{(k)}$  vérifiant  $g'(t^{(k)}) = 0$ . Or,  $g'(t) = \langle \nabla f(x_t) | d^{(k)} \rangle$ , soit

$$\begin{aligned} g'(t^{(k)}) = 0 &\iff \langle Q(x^{(k)} + t^{(k)}d^{(k)}) + b | d^{(k)} \rangle = 0 \\ &\iff t^{(k)} \langle Qd^{(k)} | d^{(k)} \rangle - \langle d^{(k)} | d^{(k)} \rangle = 0. \end{aligned}$$

Ainsi,  $t^{(k)} = \langle d^{(k)} | d^{(k)} \rangle / \langle Qd^{(k)} | d^{(k)} \rangle$ . En résumé, dans le cas d'une fonction  $f$  de la forme considérée, l'algorithme de descente de gradient à pas optimal s'écrit

$$\begin{cases} d^{(k)} = -(Qx^{(k)} + b) \\ t^{(k)} = \frac{\langle d^{(k)} | d^{(k)} \rangle}{\langle Qd^{(k)} | d^{(k)} \rangle} \\ x^{(k+1)} = x^{(k)} + t^{(k)}d^{(k)}. \end{cases} \quad (2.2)$$

On suppose dans la suite que l'ensemble

$$S = \{x \in \mathbb{R}^d \mid f(x) \leq f(x^{(0)})\} \text{ est compact,} \quad (2.3)$$

ce qui garantit (proposition 2) l'existence d'un minimiseur de  $f$  sur  $\Omega$ .

**Lemme 14.** *Sous l'hypothèse (2.3), le minimum dans la définition du pas est atteint.*

*Démonstration.* Il s'agit de démontrer que la fonction  $g : t \mapsto f(x^{(k)} + td^{(k)})$  atteint son minimum. On suppose que  $d^{(k)}$  est non nul : sinon  $g$  est constante et atteint évidemment son minimum. Grâce à la proposition 2, il suffit de montrer que le sous-niveau  $S_g := \{t \in \mathbb{R} \mid g(t) \leq f(x^{(k)})\}$  est compact. Ce sous-niveau est fermé comme image inverse du fermé  $]-\infty, f(x^{(k)})]$  par la fonction continue  $g$ . Montrons maintenant que  $S_g$  est borné. Pour cela, nous utilisons l'hypothèse que  $S$  est compact donc borné :  $\exists R \geq 0, \forall x \in S, \|x\| \leq R$ . Si  $t \in S_g$ , alors  $x^{(k)} + td^{(k)} \in S$ , de sorte que

$$\|x^{(k)} + td^{(k)}\| \leq R$$

soit

$$|t| \leq \frac{R + \|x^{(k)}\|}{\|d^{(k)}\|}.$$

Ainsi  $S_g$  est compact et par la proposition 2,  $g$  atteint son minimum sur  $\mathbb{R}$ .  $\square$

**Théorème 15.** Soit  $f \in \mathcal{C}^2(\mathbb{R}^d)$  vérifiant

- (i) le sous-niveau  $S = \{x \in \mathbb{R}^d \mid f(x) \leq f(x^{(0)})\}$  est compact.
- (ii)  $\exists M > 0, \forall x \in S, D^2f(x) \preceq M\text{Id}$ ,
- (iii)  $f$  est strictement convexe,

Alors les itérées de l'algorithme (2.1) convergent vers l'unique minimiseur global de  $f$  sur  $\Omega$ .

On utilisera la proposition suivante :

**Proposition 16.** Soit  $(x_k)_{k \geq 1}$  une suite bornée de  $\mathbb{R}^d$  admettant une unique valeur d'adhérence  $\bar{x}$ .<sup>a</sup> Alors,  $\lim_{k \rightarrow +\infty} x_k = \bar{x}$ .

<sup>a</sup>. On rappelle que  $\bar{x}$  est valeur d'adhérence de la suite  $(x_k)_{k \geq 1}$  si et seulement si il existe une suite extraite  $(x_{\sigma(k)})_{k \geq 1}$  dont la limite est  $\bar{x}$

*Démonstration du théorème 15.* Soit  $k \geq 1$  et  $g(t) = f(x^{(k)} + td^{(k)}) = f(x^{(k)} - t\nabla f(x^{(k)}))$ . Par définition du pas optimal  $t^{(k)}$  on a

$$f(x^{(k+1)}) = \min_t f(x^{(k)} + td^{(k)}) = \min_t g(t),$$

et nous allons utiliser un développement de Taylor pour estimer le minimum de  $g$ . Par le lemme 8, et en posant  $x_t = x^{(k)} + td^{(k)}$  on a

$$g'(t) = \langle \nabla f(x_t) | d^{(k)} \rangle, \quad g''(t) = \langle D^2f(x_t) d^{(k)} | d^{(k)} \rangle.$$

Soit  $\sigma = \{t \in \mathbb{R} \mid x_t \in S\}$  et  $t \in \sigma$ . Par Taylor-Lagrange, pour tout  $t \in \sigma$ , il existe  $s \in [0, t]$  tel que  $g(t) = g(0) + tg'(0) + \frac{t^2}{2}g''(s)$ . Ainsi,

$$\begin{aligned} g(t) &= g(0) + tg'(0) + \frac{t^2}{2}g''(s) \\ &= f(x^{(k)}) - t \left\| \nabla f(x^{(k)}) \right\|^2 + \frac{t^2}{2} \langle D^2f(x_s) \nabla f(x^{(k)}) | \nabla f(x^{(k)}) \rangle \end{aligned}$$

Comme  $s \in [0, t]$ , alors  $s = \gamma t$  avec  $\gamma \in [0, 1]$  de sorte que  $f(x_s) = f((1-\gamma)x_0 + \gamma x_t) \leq f(x^{(0)})$ . Ainsi,  $x_s \in S$ . Par hypothèse, on a donc  $D^2f(x_s) \preceq M\text{Id}$ , ce qui donne en utilisant (ii)

$$g(t) \leq f(x^{(k)}) + \left( \frac{M}{2}t^2 - t \right) \left\| \nabla f(x^{(k)}) \right\|^2$$

Le minimum de ce second membre est atteint en  $t = 1/M$  et on a donc

$$f(x^{(k+1)}) \leq \min_t g(t) \leq f(x^{(k)}) - \frac{1}{2M} \left\| \nabla f(x^{(k)}) \right\|^2,$$

de sorte que

$$\left\| \nabla f(x^{(k)}) \right\|^2 \leq 2M(f(x^{(k)}) - f(x^{(k+1)})). \quad (2.4)$$

Ainsi, pour tout  $K \geq 0$  on a

$$\sum_{0 \leq k \leq K} \left\| \nabla f(x^{(k)}) \right\|^2 \leq 2M(f(x^{(0)}) - f(x^{(K)})) \leq 2M(f(x^{(0)}) - \inf_{\mathbb{R}^d} f).$$

La série de terme général  $\left\| \nabla f(x^{(k)}) \right\|^2$  est donc convergente, d'où l'on déduit que  $\lim_{k \rightarrow +\infty} \left\| \nabla f(x^{(k)}) \right\| = 0$ .

Montrons enfin que  $\lim_{k \rightarrow +\infty} x^{(k)} = x^*$ , où  $x^*$  est l'unique minimum de  $f$  sur  $\mathbb{R}^d$ , l'unicité provenant de la stricte convexité de  $f$  et de la proposition 12. Comme  $f(x^{(k)}) \leq f(x^{(0)})$ , le point  $x^{(k)}$  appartient à  $S$ , qui est par hypothèse compact donc borné. Pour montrer que la suite  $x^{(k)}$  converge vers  $x^*$ , il suffit par la proposition 16 de démontrer qu'elle admet  $x^*$  pour seule valeur d'adhérence. Soit donc  $(x^{(\sigma(k))})$  une sous-suite convergeant vers une valeur d'adhérence  $\bar{x} \in S$ . Alors, comme  $f \in \mathcal{C}^1(\mathbb{R}^d)$ ,  $\nabla f(\bar{x}) = \lim_{k \rightarrow +\infty} \nabla f(x^{(\sigma(k))}) = 0$ . Par convexité (théorème 11), on sait que  $\bar{x}$  est un minimiseur de  $f$  sur  $\mathbb{R}^d$ . Par unicité du minimiseur, on en déduit que  $\bar{x} = x^*$ .  $\square$

# Bibliographie

- [1] Hedy Attouch, Giuseppe Buttazzo, and Gérard Michaille. *Variational analysis in Sobolev and BV spaces : applications to PDEs and optimization*, volume 17. SIAM, 2014.
- [2] Stephen Boyd and Lieven Vandenberghe. *Convex optimization*. Cambridge university press, 2004.
- [3] Guillaume Carlier. *Classical and Modern Optimization*. World Scientific, 2022.
- [4] Jean Dieudonné. Elements d’analyse. tome ii : Chapitres xii a xv. 1969.
- [5] Jean-Baptiste Hiriart-Urruty and Claude Lemaréchal. *Fundamentals of convex analysis*. Springer Science & Business Media, 2001.
- [6] Robert R. Phelps. *Convex functions, monotone operators and differentiability*. Springer-Verlag, 1989.